

人工智能关键技术的发展现状与趋势研究

李培源, 曾卫民, 赵 帅, 韦安垒

(天翼云科技有限公司, 北京 100007)

摘要: 在当今全球科技革命和产业变革中, 人工智能处于最前沿的领域。本文对人工智能领域的各项关键技术的发展现状和趋势进行综述和探讨。诸如: AI 芯片通过制程优化、架构创新提升算力; 芯片使能技术优化软件架构, 提升异构融合能力; AI 开发框架增强兼容性、灵活性和可移植性; 大模型在复杂任务处理、多模态信息整合方面取得突破; 云智一体推动算力、算法和数据深度融合, 促进 AI 产业生态形成, 等。这些技术共同推动 AI 向更高效、更智能和更广领域应用发展。通过本研究, 我们期望能够为政策制定者、科研人员和行业从业者提供有益的参考和启示。

关键词: AI 芯片; 芯片使能; AI 开发框架; 大模型; 云智一体

本文著录格式: 李培源, 曾卫民, 赵帅, 等. 人工智能关键技术的发展现状与趋势研究[J]. 新一代信息技术, 2024, 7(1): 36-40

中图分类号: TP18

文献标识码: A

Research on the Development Status and Trends of Key Technologies in Artificial Intelligence

LI Pei-yuan, ZENG Wei-min, ZHAO Shuai, WEI An-lei

(China Telecom Cloud Computing Corporation, Beijing 100007, China)

Abstract: In the ongoing global technological revolution and industrial transformation, artificial intelligence (AI) stands at the forefront. This paper reviews and discusses the current status and trends of various key technologies in the field of AI. Specifically, AI chips enhance computing power through process optimization and architectural innovation; Chip-enabling technologies optimize software architectures, thereby improving heterogeneous integration capabilities; AI development frameworks bolster compatibility, flexibility, and portability; Large models have made breakthroughs in handling complex tasks and integrating multimodal information; The integration of cloud computing and AI promotes the deep fusion of computing power, algorithms, and data, facilitating the formation of an AI industrial ecosystem. These technologies collectively propel AI towards more efficient, intelligent, and widespread applications. Through this research, we aspire to provide valuable reference and insights for policymakers, researchers, and industry practitioners.

Key words: AI chips; chips enabling; AI development frameworks; large model; cloud-AI integration

Citation: LI Pei-yuan, ZENG Wei-min, ZHAO Shuai, et al. Research on the Development Status and Trends of Key Technologies in Artificial Intelligence[J]. New Generation of Information Technology, 2024, 7(1): 36-40

1 引言

人工智能(Artificial Intelligence, AI)是利用数字计算机或者数字计算机控制的机器, 模拟、延伸和扩展人的智能, 感知环境、获取知识并使用知识获得最佳结果的理论、方法、技术及应用系统^[1]。在当今数字化、智能化高速发展的时代, 人工智能正以前所未有的速度渗透到我们生活的方方面面, 成为推动社会进步和经济发展的关键力量。据麦肯锡全球研究所预测, 到2030年, 人

工智能将为全球经济额外贡献13万亿美元GDP增长, 每年推动全球GDP增长约1.2%。在人工智能的发展和应用过程中, AI芯片、大模型、云智一体等关键技术发挥着至关重要的作用, 也不断进行着迭代和演化。

2 人工智能关键技术体系框架

人工智能的概念自1956年达特茅斯会议被首次提出以来, 其间经过符号主义、联结主义、行为主义三大学派的起伏发展^[2], 逐步从逻辑推理、专家系统、机

器学习、深度学习走向基于深度神经网络的AIGC阶段,至今已有近70年的历史。近年来,随着GPT系列模型的不断演进,人工智能领域的各项关键技术取得了颠覆性的、指数级的发展,围绕大模型及相关算力、算法等驱动要素逐渐形成了一套完整的体系框架,如图1所示。




图1 人工智能关键技术体系框架图

该体系框架将人工智能关键技术分为AI芯片技术、芯片使能技术、AI开发框架技术、大模型技术和云智一体技术5类。其中AI芯片技术从硬件层面满足了不断升高的算力要求,芯片使能技术帮助芯片解决并行加速、异构协同等问题,AI开发框架技术为上层的模型、算法开发提供了一整套工具包,大模型技术因其强大的能力成为了当前人工智能落地应用的核心支撑,云智一体技术则通过深度融合实现效能提升,不断创新应用场景。以下章节将对5类技术的发展现状和趋势进行浅析。

3 人工智能关键技术发展现状与趋势

3.1 AI芯片

AI芯片是专为加速人工智能应用而设计的处理器。这类芯片针对人工智能算法中的大量计算和数据处理需求进行了优化,旨在提供更高的计算效率、更低的能耗以及更强的处理能力,从而满足复杂的人工智能任务需求。AI芯片根据其技术架构可以分为4类:图形处理器(Graphics Processing Unit, GPU)、现场可编程门阵列(Field Programmable Gate Array, FPGA)、专用集成电路(Application Specific Integrated Circuit, ASIC)、神经网络处理器(Neural Processing Unit, NPU)^[3]。

GPU芯片原本是为图形渲染而设计,但因其强大的并行处理能力,也被广泛应用于人工智能领域,其能够同时处理多个任务,适用于深度学习等需要大量矩阵运算的算法,在过去10多年中GPU芯片通过不断优化微架构,计算性能提升超过300倍;FPGA芯片是一种可以在硬件层面进行编程的芯片,具有高度的灵活性和较低的能耗,用户可以根据特定的算法需求对FPGA芯片进行定制化的配置,以实现高效的计算性能,还支持通过编程对基本门电路和存储器重新定义,因此适合于芯片功能尚未完全定型、算法仍需不断迭代完善的场景;ASIC芯片是基于特定场景需求完全定制化的芯片,其在底层硬件编程过程中需要大量的物理设计、时间、资金及验证,但在量产后具有性能更好、功耗更低的优点;NPU芯片是针对神经网络计算专门设计的处理器,它能够在电路层面模拟人类的神经元与突触结构,并且直接利用深度学习指令集来处理大规模的神经元与突触数据。这种设计通过突触权重的方式实现了存储与计算的一体化,显著提升了运行效率^[4]。

从发展趋势看,GPU芯片目前仍是AI芯片的主要技术路径。在单一GPU层面,可通过制程迭代提升单位面积晶体管密度来影响芯片的算力和性能表现,也可通过升级微架构改变数据计算方式、存储方式及流向,从而提升性能。在多GPU层面,可通过Chiplet(芯粒)技术实现不同功能的小芯片组合,从而提高芯片的性能。2024年发布的Blackwell架构图形处理器,就是利用Chiplet技术实现GPU芯片的拼接,进一步提高GPU的计算密度,最终达到计算性能提升的目的^[5]。

3.2 芯片使能

芯片使能主要是指通过软件技术驱动芯片更好地支持和加速人工智能算法的运行,解决不同芯片之间通信接口延迟高、数据传输效率差、内存访问和同步复杂、程序开发和移植困难、任务分配和协调困难等问题。

在实际应用中,英伟达公司开发的CUDA(Compute Unified Device Architecture)作为一款通用高性能并行计算平台和编程模型,是芯片使能软件的代表。CUDA提供了一个完整的开发工具套件,使得开发者能够更方便地编写、调试和优化基于GPU的并行程序。通过使用CUDA,线程和内存的层次结构得到了扩展,类似CUDA的代码能够在多节点、多GPU系统上运行,使英伟达GPU强大的并行计算能力得到充分利用,加速了各种计算密集型的场景任务^[6]。

从发展趋势看,CUDA作为芯片使能技术的代表,

将从以下几个方面不断进行优化:一是不断对核心架构进行升级,在架构层面提升并行计算能力和效率,通过改进内存管理、降低延迟、提高吞吐量等手段,更好地满足复杂计算任务的需求,最新版本的 CUDA 架构采用了更先进的制程工艺和更高效的内存管理系统,使得 GPU 在处理复杂任务时更加得心应手;二是不断简化编程模型,提供更为友好的编程接口和工具链,使得更多开发者能够轻松上手 CUDA 编程,释放其强大潜能,最新的 CUDA 版本已经引入了更简洁的语法和更直观的编程接口,使开发者能够更轻松地编写出高效的 GPU 代码;三是不断与新兴技术进行更紧密地融合,拓展其应用场景,例如借助 5G 的高速传输能力, CUDA 可以实现远程实时计算和数据处理,通过云计算平台 CUDA 可以为更多用户提供弹性、高效的计算资源;四是不断提升异构计算融合能力,异构计算已经成为一种趋势, CUDA 通过与其他计算技术的融合,能够充分发挥各种计算资源的优势,实现更高效的任務分配和执行,这种异构计算融合不仅提升了计算性能,还降低了能耗和成本。

3.3 AI 开发框架

AI 开发框架是一套集成了算法封装、数据调用和计算资源使用的标准接口、特性库及工具包,它专为 AI 算法模型的设计、训练和验证而设计,为开发者提供了直观的开发界面和高效的执行平台。从技术体系的功能定位来看, AI 开发框架扮演着承上启下的角色:它能够调用下层的硬件计算资源,屏蔽底层差异并确保良好的执行性能;同时它也为上层 AI 应用算法模型的构建提供了工程化实现的标准环境。

在实际应用中, AI 开发框架技术经过不断演进和激烈竞争,最终形成了两大阵营,即 TensorFlow 框架和 PyTorch 框架。TensorFlow 框架由 Google 公司在 2015 年发布,是一个使用张量和计算图描述计算过程的开放源代码软件库, TensorFlow 框架具备编程模型灵活、性能良好、社区更新速度快、硬件平台支持广泛以及文档齐备的特点,形成了良好互动的开发生态。PyTorch 框架主要由 Facebook 的人工智能研究团队开发并在 2018 年发布 1.0 稳定版本, Pytorch 框架支持动态计算图,和 TensorFlow 基于静态计算图的模型部署方式相比,在定义网络的操作上更简单,在调用函数时更灵活,在修改网络的某一层或者某些变量时也比较方便^[7]。

从发展趋势看, AI 开发框架将从以下几个方面不断进行优化:一是需要建立更加完备、性能优异、易于理解和使用的 API 体系,通过提升前端语言支持转换

能力帮助前端开发更加便捷。在产业应用实际落地过程中, AI 开发框架需通过提供配套的编程接口与功能支持,实现与 Java、C++、C#、Go 等产业级开发语言的无缝衔接。二是需要提供更为灵活的动态图、静态图转换能力,让后端运行更加高效。在模型开发部署的实际场景中, AI 开发框架需要能够通过动态图的编程范式实现灵活易用的开发体验,需要通过静态图的方式提升模型部署时的运行性能,还需要通过动态图转静态图的方式,提升部署便捷性和效率。三是需要支持端-边-云跨平台算力设备部署,通过可解耦标准化硬件注册接口、模型格式标准化、算子标准化等方案,解决多样化算力设备算法模型不通用、项目难迁移和难互通协同的问题,满足不同业务场景同步适配的业务需求。

3.4 大模型

大模型是指具有大规模参数和复杂计算结构的机器学习模型,这些模型通常由深度神经网络构建而成,拥有数十亿甚至数千亿个参数,通过在大规模数据集上进行训练,能够学习到数据中的复杂模式和规律,从而在处理复杂任务时展现出强大的性能和泛化能力。大模型技术当前已进入以 GPT 为代表的 Transformer 架构预训练大模型阶段,代码预训练技术、指令微调技术、基于人类反馈的强化学习 (Reinforcement Learning from Human Feedback, RLHF) 等技术逐步成熟^[8],模型推理能力和任务泛化水平得到进一步提升,参数规模超过万亿,应用能力也不断取得突破。OpenAI 在 2024 年 2 月发布的大模型 sora,已能够根据用户的文本指令生成最长达一分钟的高质量、高视觉连贯性视频,5 月发布的大模型 GPT-4o,已实现多模态交互和实时响应,还展现出了情绪识别能力。

从发展趋势看,稀疏大模型、长序列大模型和原生多模态大模型是目前大模型领域的重点研究方向。稀疏大模型通过将大模型中的部分参数设置为零或接近于零,在保持表达能力和泛化性能的前提下显著降低了复杂度和计算量,但同时存在着设计和实现难度高、稀疏性和准确性难以平衡的问题。长序列大模型通过扩展上下文窗口让大模型更好地捕捉全局信息,更准确地保留了原文的语义,在降低幻觉发生的同时提高了新任务的泛化能力,但会提升模型计算复杂度和难度,对算力利用率产生影响。原生多模态大模型从训练阶段开始就利用大量不同模态的数据进行预训练,使模型在输入和输出端支持多模态的同时还具备了强大的多模态推理能力、跨模态迁移能力和多模态数据联合分析能力,但目前还存在不同模态数

据融合难度大、收敛速度慢以及性能表现差等挑战。

此外,由于大模型目前仍主要基于深度神经网络实现,还存在“幻觉”效应、机理不明、缺乏决策能力、可解释性不足、能效比不高等技术瓶颈,也有应用落地场景不足等问题,还需要从以下几个方面不断进行优化:一是通过模型调优有效降低“幻觉”效应的影响,提高模型的稳定性和可靠性,例如可通过应用正则化技术和早停策略防止模型在训练过程中过拟合,提高模型的泛化能力;二是通过知识增强算法的创新提升模型智能化水平,例如可通过引入基于图神经网络的知识表示学习方法,将外部知识库(如知识图谱、常识库等)融入大模型中,帮助大模型在处理需要背景知识和常识推理的任务时更加准确和可靠;三是通过可解释性算法的应用提高模型的透明度和可信度,例如可通过引入基于注意力机制的可解释性分析方法,以可视化、文本解释等方式揭示模型的决策过程和行为模式;四是通过不断探索高效训练和优化技术提升模型训练效率,例如可通过模型剪枝技术移除模型中不重要的参数或神经元来减少模型大小,在保持模型性能的同时显著减小模型体积和推理时间^[9],或通过分布式训练、混合精度训练等手段降低计算资源和时间成本。除以上技术优化外,大模型还将更加注重与行业知识的深度融合,针对不同行业需求的定制化开发和定制化训练帮助大模型更好地适应特定行业的业务场景,形成更加贴近业务实际的解决方案,从而提升应用落地效果。

3.5 云智一体

进入AIGC时代,“云智一体”已经成为行业共识。微软的Azure和OpenAI加强垂直生态整合并提供全栈智能产品与服务;亚马逊在加大投入Anthropic的同时,与Meta旗下的Llama3不断加强合作。从全球AI产业发展趋势来看,头部AI独角兽公司的背后,都能看到头部云服务商的身影。

大模型AI是由算力、平台、模型、数据、安全、应用、用户、资本等要素组成的复杂产业链。只有头部的云服务商,有能力拉通产业链上的各个环节,并支撑AI产业实现商业闭环。在算力供给方面,业界已经出现多个万亿参数模型,十万亿参数模型亦即将出现,面对指数级增长的算力需求,只有云服务商有能力提供高性价比的智算算力供给方案。在平台和模型方面,AI厂商和云服务商正在加速生态融合,MaaS(模型即服务)已经成为行业发展的必然趋势。在数据方面,大型的公有云服务商,也有能力为模型训练提供高质量的数据资源。

目前,大模型AI产业已经逐步进入竞争的下半场,AI企业的核心使命已经从模型的研发、训练走向了应用落地和商业变现。在这个环节,云服务商将发挥更为重要的作用。一方面,头部云服务商在资本领域已加强与AI企业的协同;另一方面,云服务商依托自身在应用软件领域的合作伙伴资源加速AI应用的开发落地,同时开放用户资源向AI企业引流,加速推进AI企业实现商业变现。

从发展趋势看,大模型AI和云计算产业的深度融合,还需要在以下领域不断突破:一是需要实现高质量的算力供给方案,一方面解决单集群超大规模算力供给问题,另一方面面向大模型训推一体的场景需求,提供异构算力解决方案。二是需要加速AI应用的落地闭环和商业变现。在大型互联网公司全面进军AI产业以后,以免费应用吸引流量为主要业务形态,以短期内的用户增长为主要目标,但同质化竞争、缺少用户黏性的现象也较为突出。因此,未来要加速行业大模型AI应用的开发,在办公智能化、智能制造、自动驾驶、机器人、航运、医疗等方向深度嵌入业务场景,加速AI的商业变现。三是需要加强AI大模型的生态体系建设,特别是打造开放、活跃的开发社区,孵化、引导、扶持更多AI应用走向市场。

4 人工智能关键技术优势

经过以上分析可以看出,人工智能各项关键技术正朝更加高效、更加智能和更广领域应用的方向快速发展,不断取得创新突破。其中AI芯片通过制程优化、架构创新、多芯协同等方式持续提升算力,降低功耗。芯片使能技术在优化软件架构和简化编程模型的同时不断提升异构融合能力,帮助芯片更好发挥计算性能,满足更多复杂计算场景需求。AI开发框架围绕API体系、计算图等不断提升兼容性、灵活性和可移植性,为开发者带来更好的开发体验和更高的运行效率。大模型以算法和模型创新为核心,在复杂任务处理、多模态信息整合、提升训练效率等方面持续取得突破,应用落地效果显著改善。云智一体则以一体化底座和一站式平台的方式不断推动算力、算法和数据等要素深度融合,帮助各行各业应用更快落地的同时,促进了AI完整产业生态的形成。

5 总结与展望

人工智能正以其前所未有的发展速度深刻影响着社会的每一个角落。从AI芯片技术的不断创新,到芯片使能技术的持续优化,再到AI开发框架的成熟与多样化,以及大模型和云智一体技术的突破性进展,

每一部分都在为人工智能的广泛应用和深入发展奠定坚实的基础。未来,随着技术的不断迭代和优化,人工智能将更加智能化、高效化、人性化,量子芯片、情感智能、AI智能体等创新技术将推动人工智能向更高级别的智能迈进,使AI更好地服务于社会,为各行各业带来更加丰富的应用场景和更加卓越的业务价值。我们有理由相信,在不远的将来人工智能将构建起一个全面智能、高效协同的社会生态系统,为我们的生活带来前所未有的便利和变革。

参考文献

- [1] 赵志君, 庄馨予. 中国人工智能高质量发展: 现状、问题与方略[J]. 改革, 2023(9): 11-20.
ZHAO Z J, ZHUANG X Y. High-quality development of artificial intelligence in China: Current situation, problems and strategies[J]. Reform, 2023(9): 11-20. (in Chinese)
- [2] 朱梦珍, 尚斌, 荣爽, 等. 人工智能发展历程及与可靠性融合发展研究[J]. 电子产品可靠性与环境试验, 2023, 41(4): 1-6.
- [3] 赵玥, 肖梦燕, 罗军, 等. 人工智能芯片及测评体系分析[J]. 电子与封装, 2023, 23(5): 31-37.
ZHAO Y, XIAO M Y, LUO J, et al. Analysis of artificial intelligence chip and evaluation system[J]. Electronics & Packaging, 2023, 23(5): 31-37. (in Chinese)
- [4] 曹震, 张浴轩, 李灵蕾, 等. 神经形态器件的特性与发展[J]. 电子学报, 2023, 51(12): 3619-3642.
CAO Z, ZHANG Y X, LI L L, et al. A comprehension survey on the characterization and development of neuromorphic devices[J]. Acta Electronica Sinica, 2023, 51(12): 3619-3642. (in Chinese)
- [5] 王晨, 邓昌义, 李嘉伟, 等. 人工智能芯片测评研究现状及未来研究趋势[J]. 新型工业化, 2021, 11(10): 82-84, 87.
WANG C, DENG C Y, LI J W, et al. Research status and future research trends of artificial intelligence chip evaluation[J]. The Journal of New Industrialization, 2021, 11(10): 82-84, 87. (in Chinese)
- [6] 张志伟, 田果, 王世权. 先进封装Chiplet技术与AI芯片发展[J]. 中阿科技论坛(中英文), 2023(11): 90-94.
ZHANG Z W, TIAN G, WANG S Q. Research on advanced packaging chiplet and AI chip development[J]. China-Arab States Science and Technology Forum, 2023(11): 90-94. (in Chinese)
- [7] 王强, 苏乐, 谢智刚. 人工智能框架技术趋势研究[J]. 智能安全, 2023(1): 46-52.
WANG Q, SU L, XIE Z G. Research on the trend of AI framework technology[J]. Artificial Intelligence Security, 2023(1): 46-52. (in Chinese)
- [8] 刘学博, 户保田, 陈科海, 等. 大模型关键技术与未来发展方向: 从ChatGPT谈起[J]. 中国科学基金, 2023, 37(5): 758-766.
LIU X B, HU B T, CHEN K H, et al. Key technologies and future development directions of large language models: Insights from ChatGPT[J]. Bulletin of National Natural Science Foundation of China, 2023, 37(5): 758-766. (in Chinese)
- [9] 刘奇, 陈莹. 正则化机制下多粒度神经网络剪枝方法研究[J]. 电子学报, 2023, 51(8): 2202-2212.
LIU Q, CHEN Y. Research on multi-granularity neural network pruning method with regularization mechanism[J]. Acta Electronica Sinica, 2023, 51(8): 2202-2212. (in Chinese)

作者简介



李培源 (1977—), 男, 博士, 现为天翼云科技有限公司部门总经理、高级工程师。研究方向: 云计算、信创、企业数字化等。
E-mail: lipeiyuan@chinatelecom.cn



曾卫民 (1972—), 男, 硕士, 现为天翼云科技有限公司副总经理、高级工程师。研究方向: 云计算、人工智能等。
E-mail: zengwm@chinatelecom.cn



赵帅 (1987—), 男, 硕士, 现为天翼云科技有限公司产品管理专家。研究方向: 人工智能领域的技术、产品及生态建设等。
E-mail: mnszhao@163.com



韦安垒 (1991—), 男, 硕士, 现为天翼云科技有限公司产品管理专家、中级工程师, 研究方向: 云计算, 信创, 自主可控等。
E-mail: hiweile@163.com